El sistema nervioso digital detrás de Uber

Una disección arquitectónica del pipeline de datos que transforma millones de señales caóticas en decisiones de negocio en tiempo real.

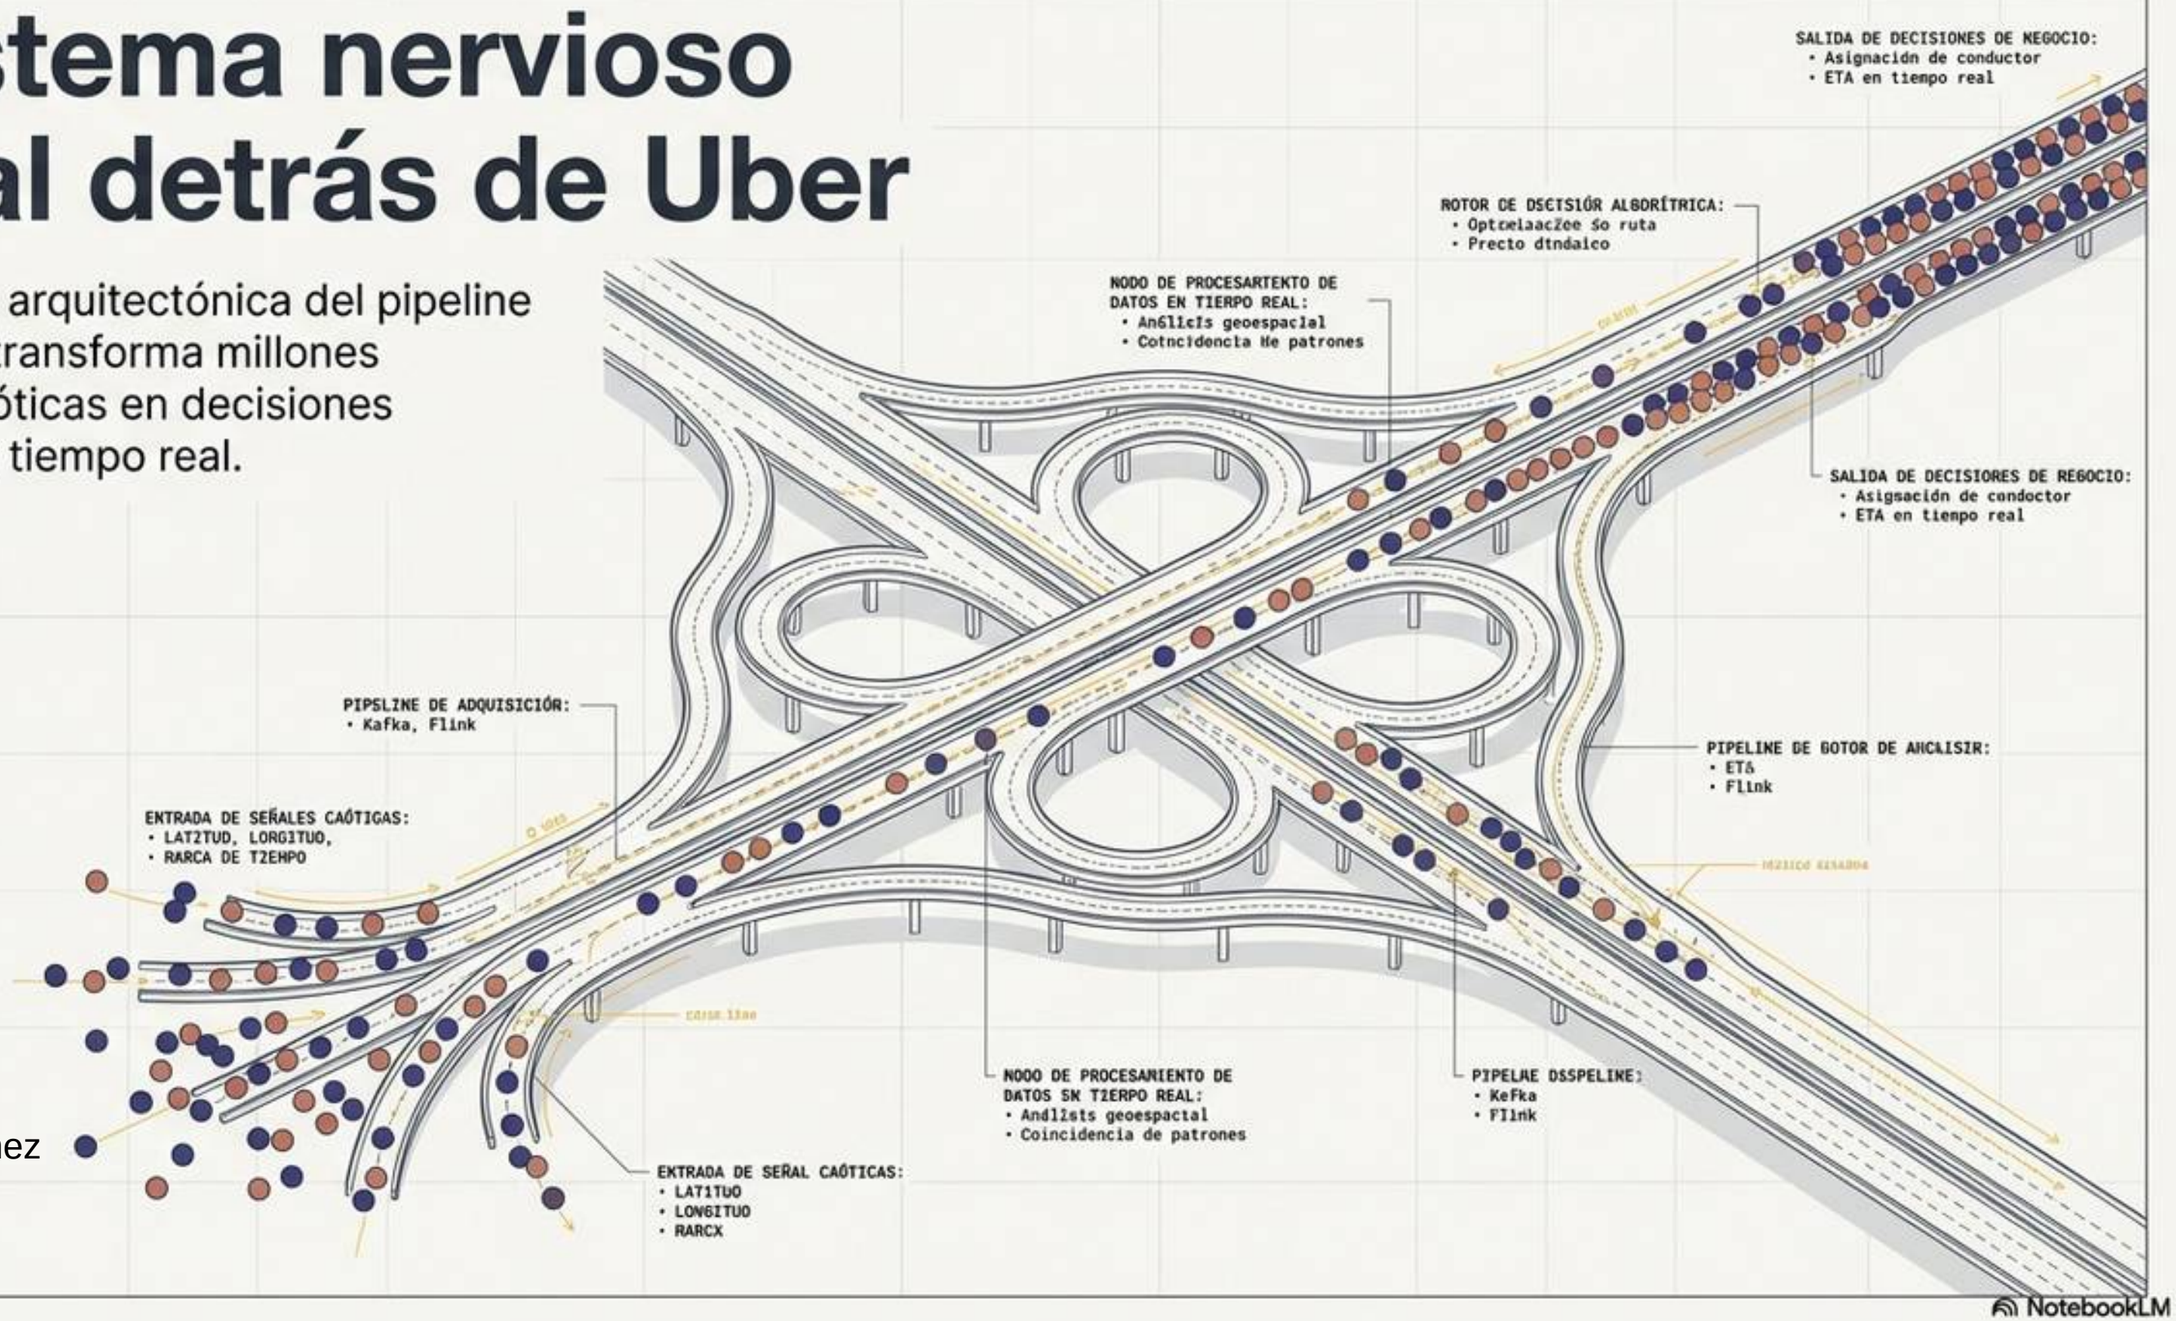

Dr. Julio Lopez-Nunez
2026

NotebookLM

El problema operativo de los 100 petabytes

Desde su fundación en 2009, el crecimiento global de Uber generó un volumen de información imposible de gestionar con bases de datos tradicionales. El desafío principal es el tiempo: la rentabilidad depende de procesar terabytes de telemetría con una latencia de un minuto o menos.

Millones de usuarios concurrentes

Geolocalización **GPS** en **tiempo real**

100+ Petabytes de datos históricos

Volumen Masivo + Latencia Cero = Necesidad de una Nueva Arquitectura

NotebookLM

Anatomía de un pipeline de datos a gran escala

Un pipeline de datos es la arquitectura estructurada que recolecta, procesa y sirve la información. Este modelo de 5 etapas asegura que los datos fluyan desde los teléfonos móviles móviles hasta los tableros de los ejecutivos de forma consistente, confiable y escalable.

NotebookLM

Toda interacción física genera una huella digital

El modelo de negocio opera recolectando eventos heterogéneos generados de forma continua por múltiples actores y sistemas en la ciudad.

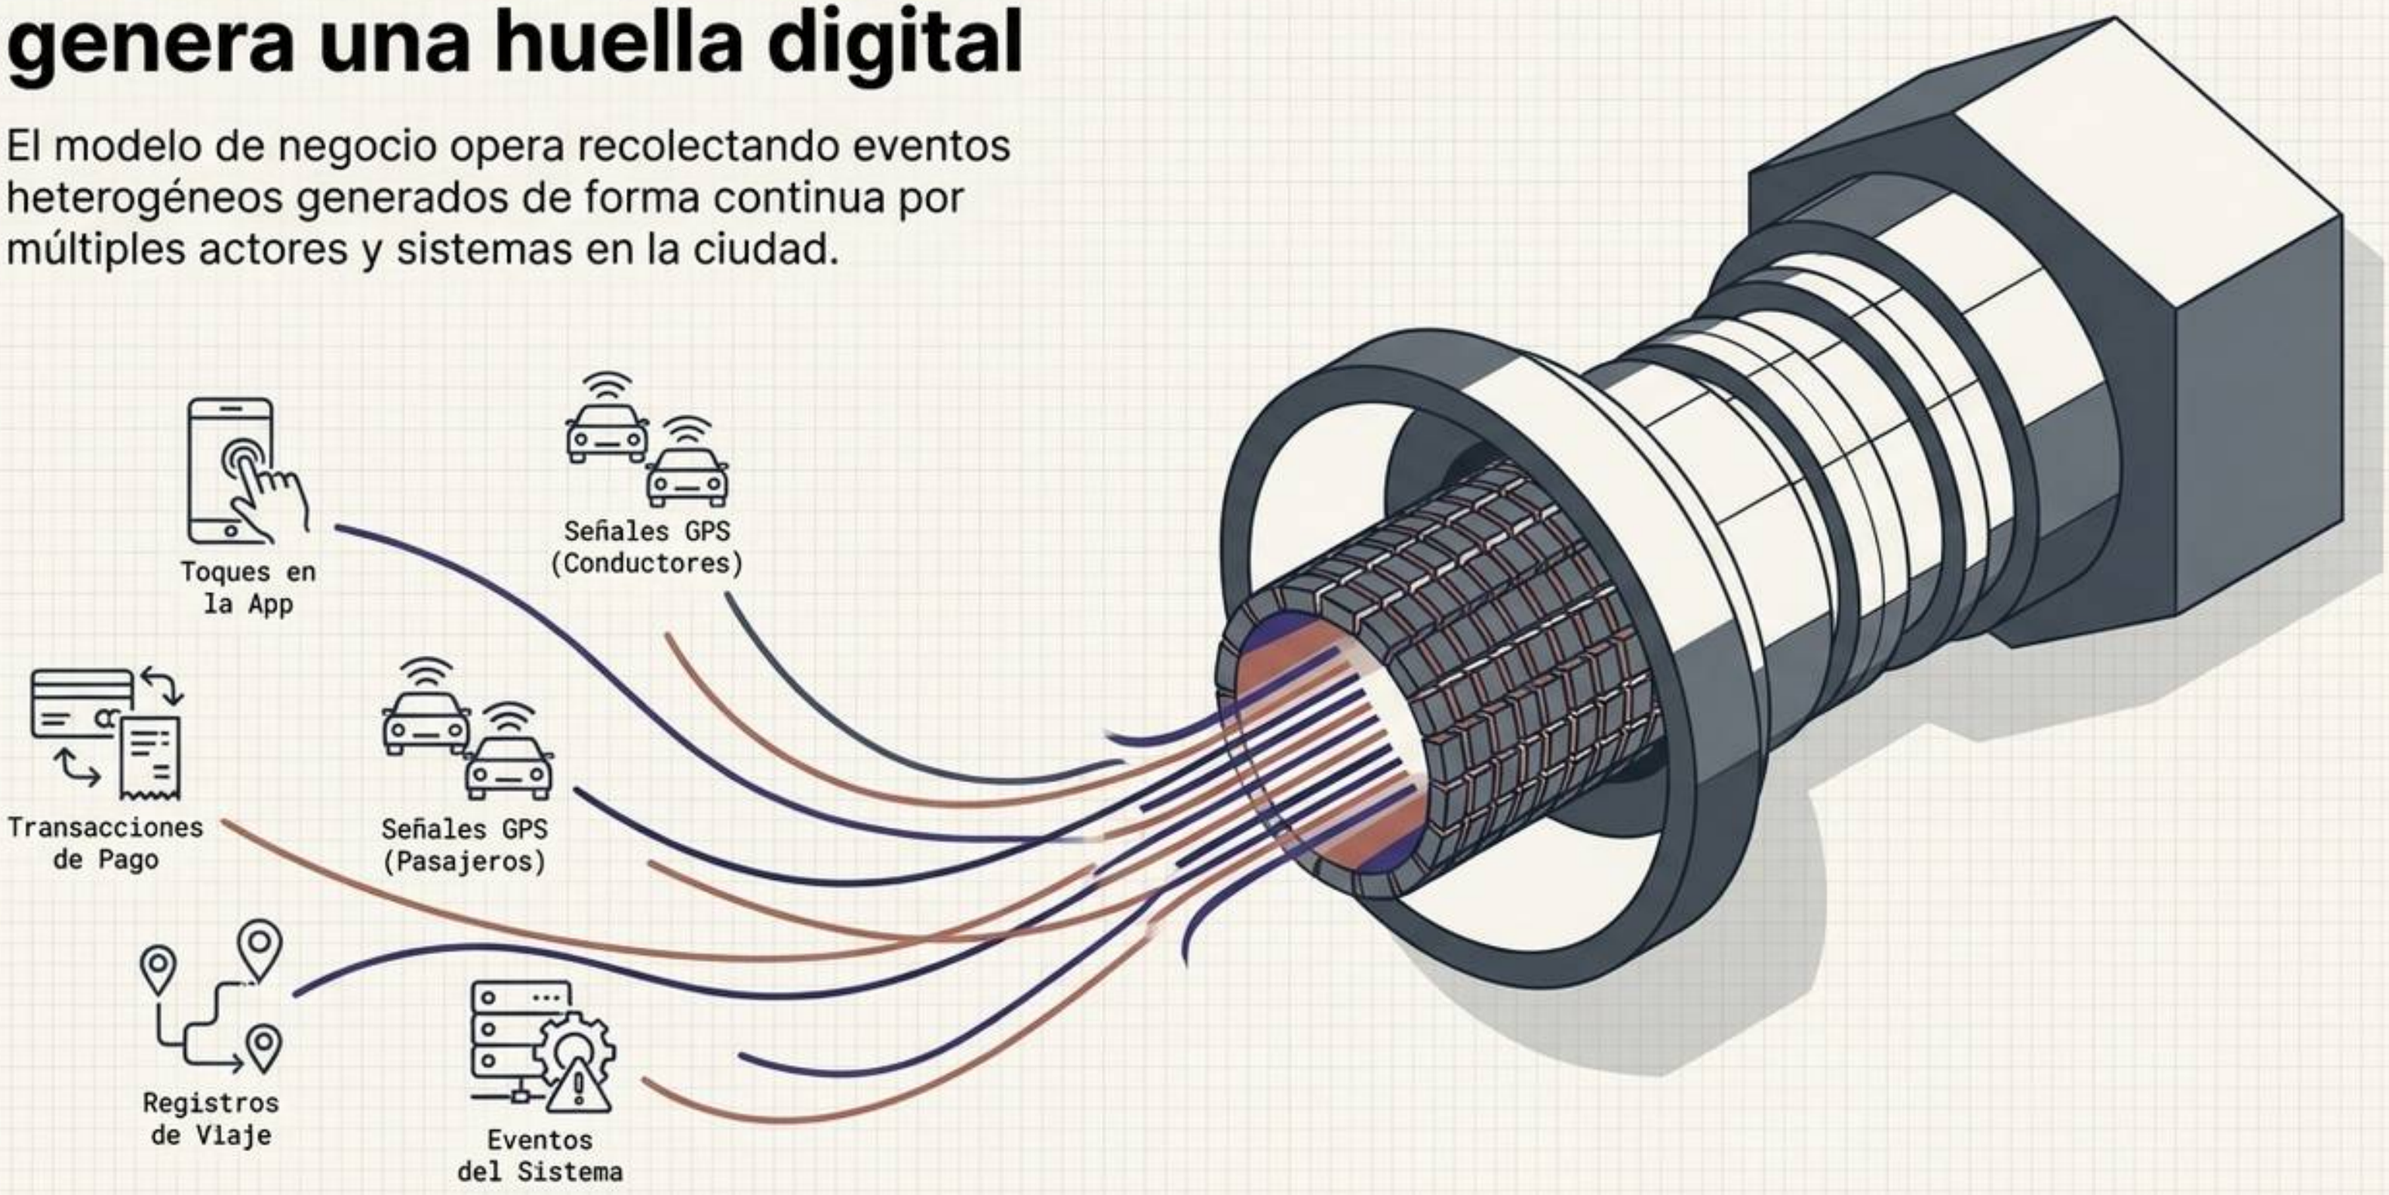

NotebookLM

Capturando el caos sin pérdida de información

La ingestión actúa como una red de seguridad de alta velocidad. Utilizando sistemas de mensajería distribuida como Apache Kafka, Uber captura millones de eventos por segundo, ordenándolos cronológicamente con una latencia mínima antes de que sigan su camino.

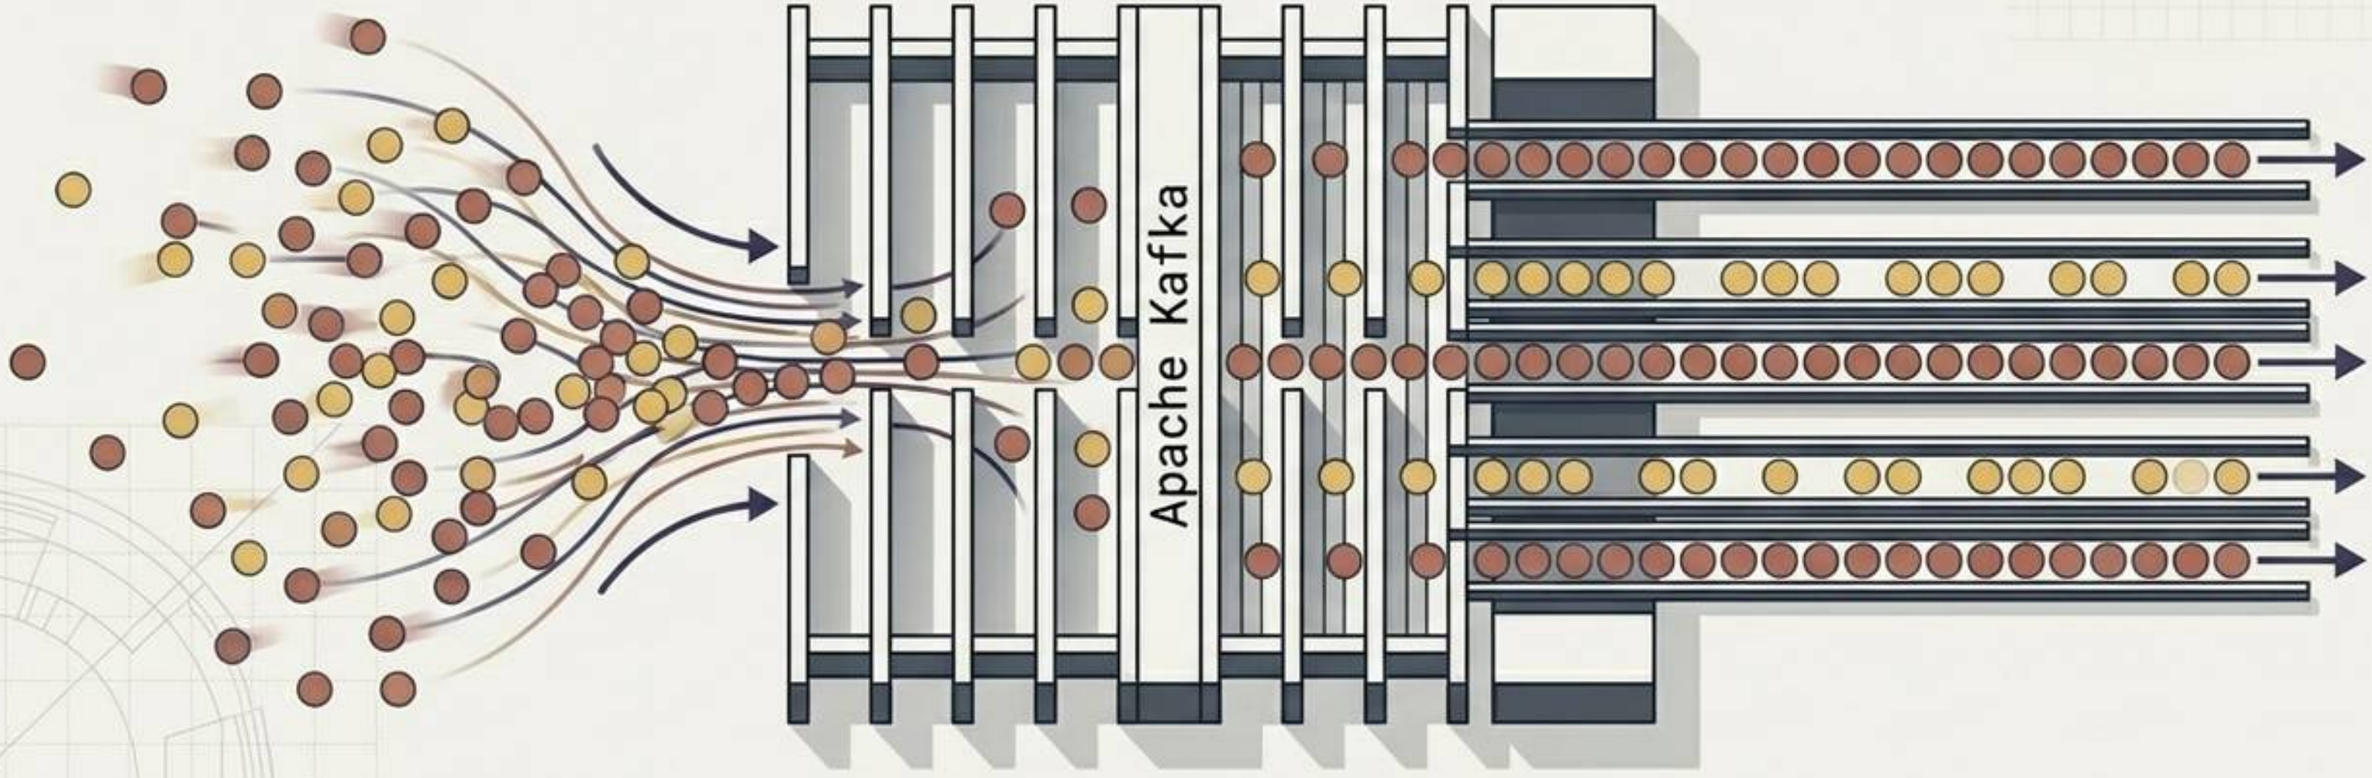

NotebookLM

Refinando la materia prima para el análisis

Los datos crudos están llenos de errores y formatos incompatibles. Frameworks distribuidos como Apache Spark transforman estos eventos aplicando cuatro procesos fundamentales a escala masiva.

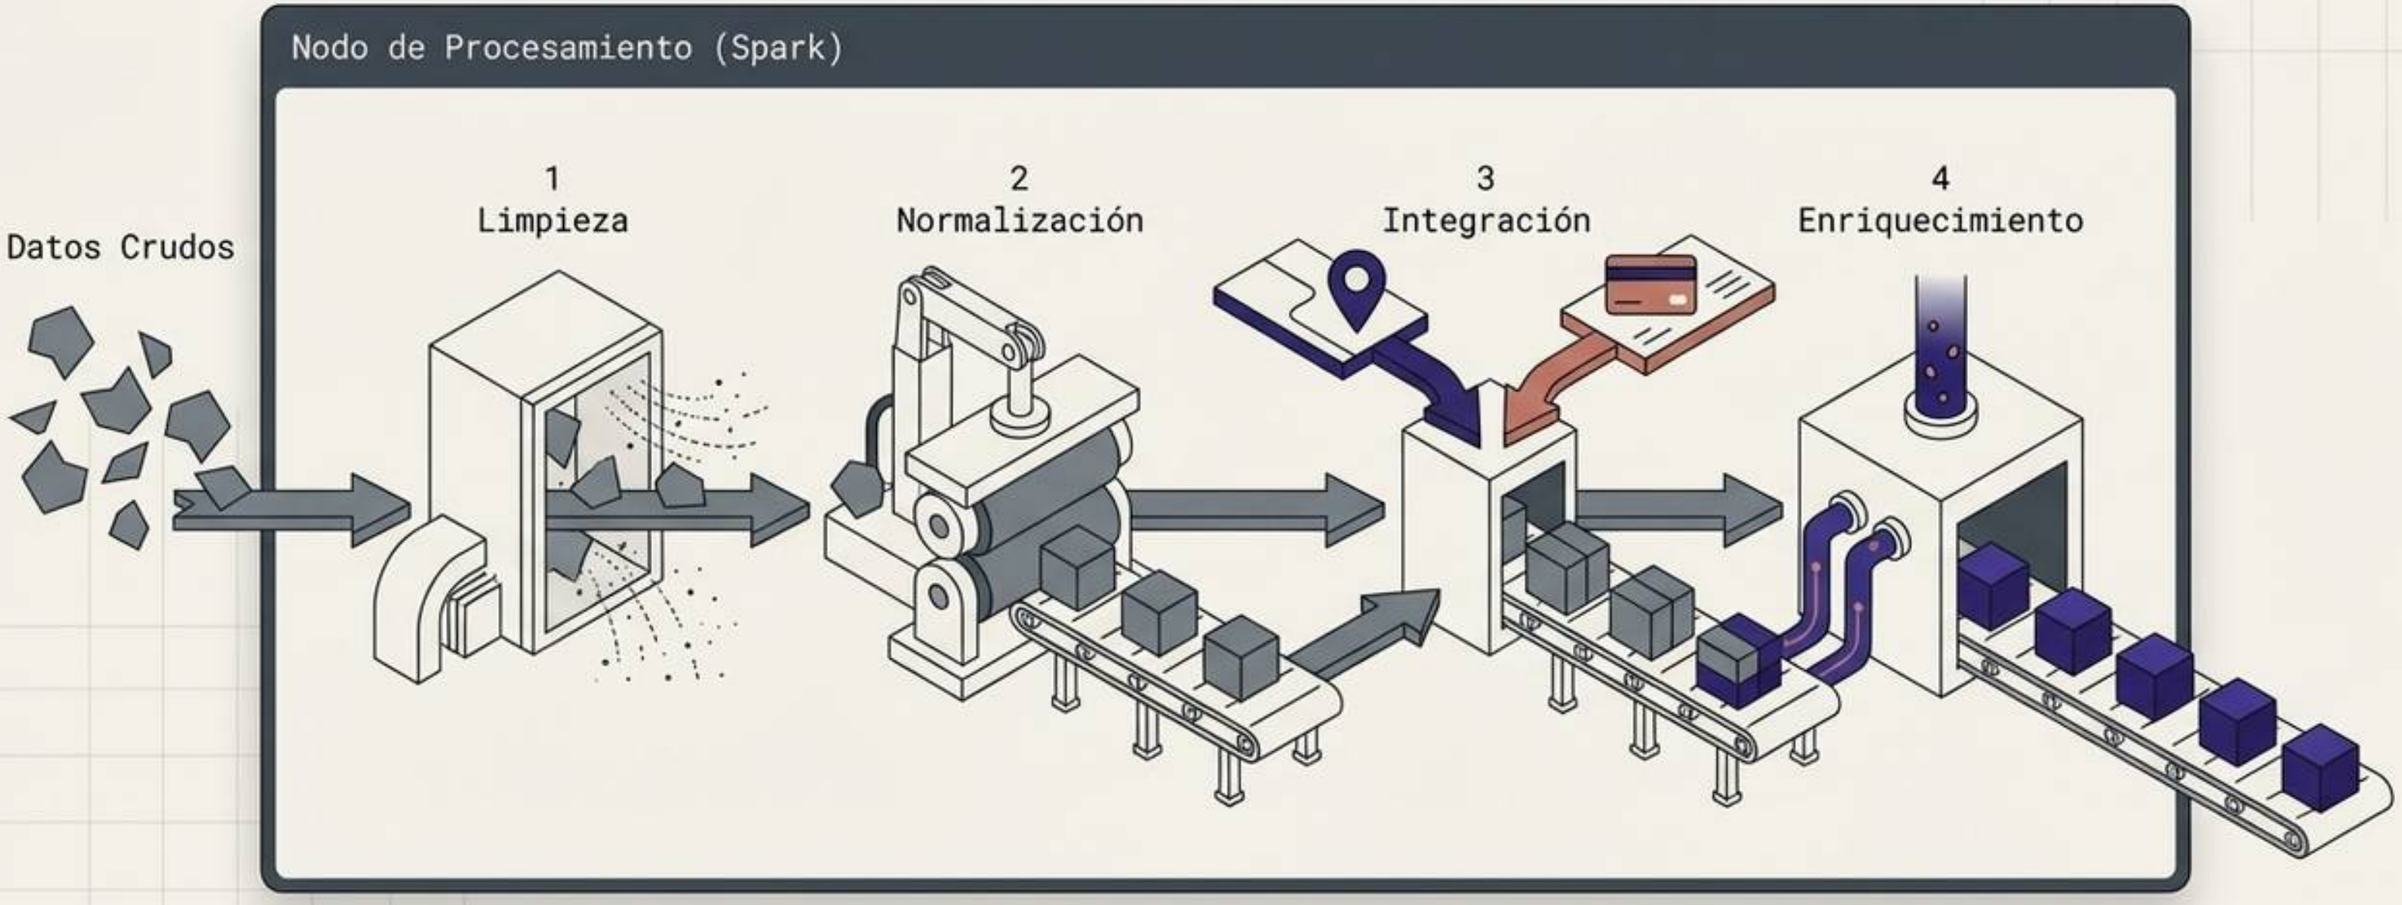

NotebookLM

Dos velocidades de procesamiento para distintas necesidades

El pipeline bifurca los datos según la urgencia del **negocio. Algunas decisiones** requieren respuestas en milisegundos; otras, una **perspectiva histórica consolidada.**

	Procesamiento en Tiempo Real (Stream)	**Procesamiento por Lotes (Batch)**
`Velocidad (Latencia)`	Milisegundos a segundos	Horas a días
`Objetivo Analítico`	Reacción operativa inmediata	Consolidación histórica profunda
`Tecnología Típica`	Spark Streaming, Kafka Streams	Spark Batch, Hadoop
`Caso de Uso en Uber`	Tarifa dinámica (Surge), Predicción de demanda actual	Reportes financieros mensuales, Entrenamiento de modelos ML

NotebookLM

Repositorios analíticos: Archivo histórico vs. Motor de consultas

Los datos procesados se almacenan según su grado de estructuración y el usuario final que los consumirá. Una arquitectura moderna requiere ambos repositorios trabajando en conjunto.

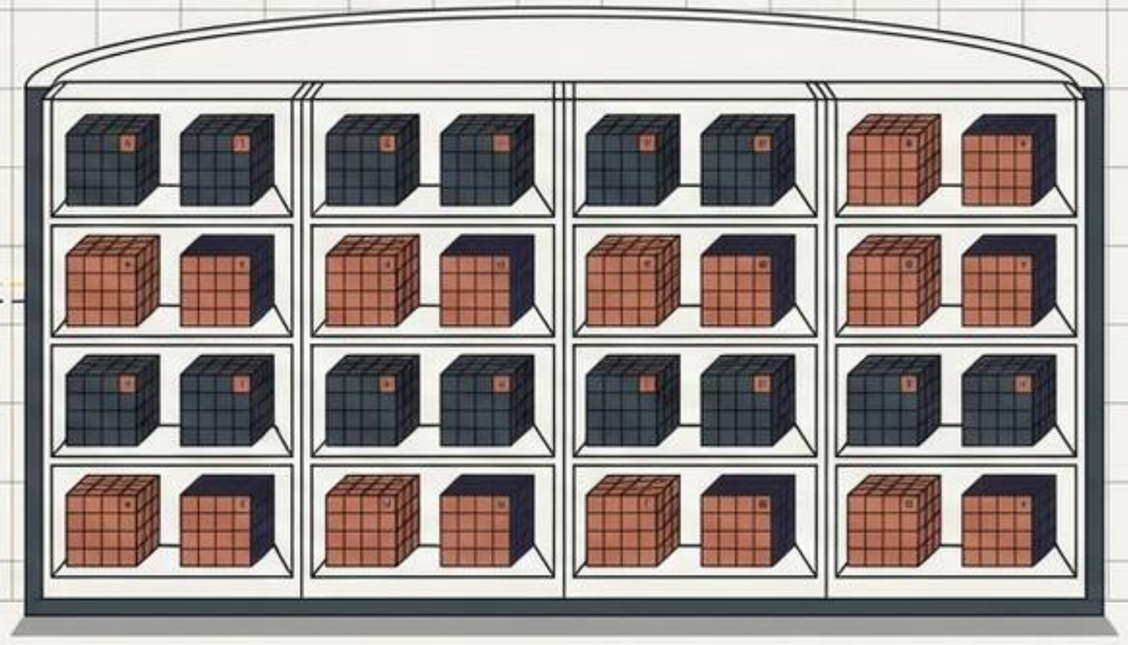

Data Lake

- **Estructura:** Crudos, semi-estructurados y no estructurados.
- **Propósito:** Exploración sin límites, almacenamiento masivo de bajo costo.
- **Usuarios:** Ingenieros de Datos, Data Scientists (e.g., plataforma Michelangelo).

Data Warehouse

- **Estructura:** Altamente modelados, relacionales y optimizados.
- **Propósito:** Consultas analíticas de alta velocidad y Dashboards de BI.
- **Usuarios:** Analistas de Negocio, Ejecutivos.

NotebookLM

Estructurando la realidad urbana en un modelo dimensional

Para que las consultas en el Data Warehouse sean instantáneas, los datos se estructuran utilizando esquemas de estrella. Las métricas centrales se separan del contexto que las rodea.

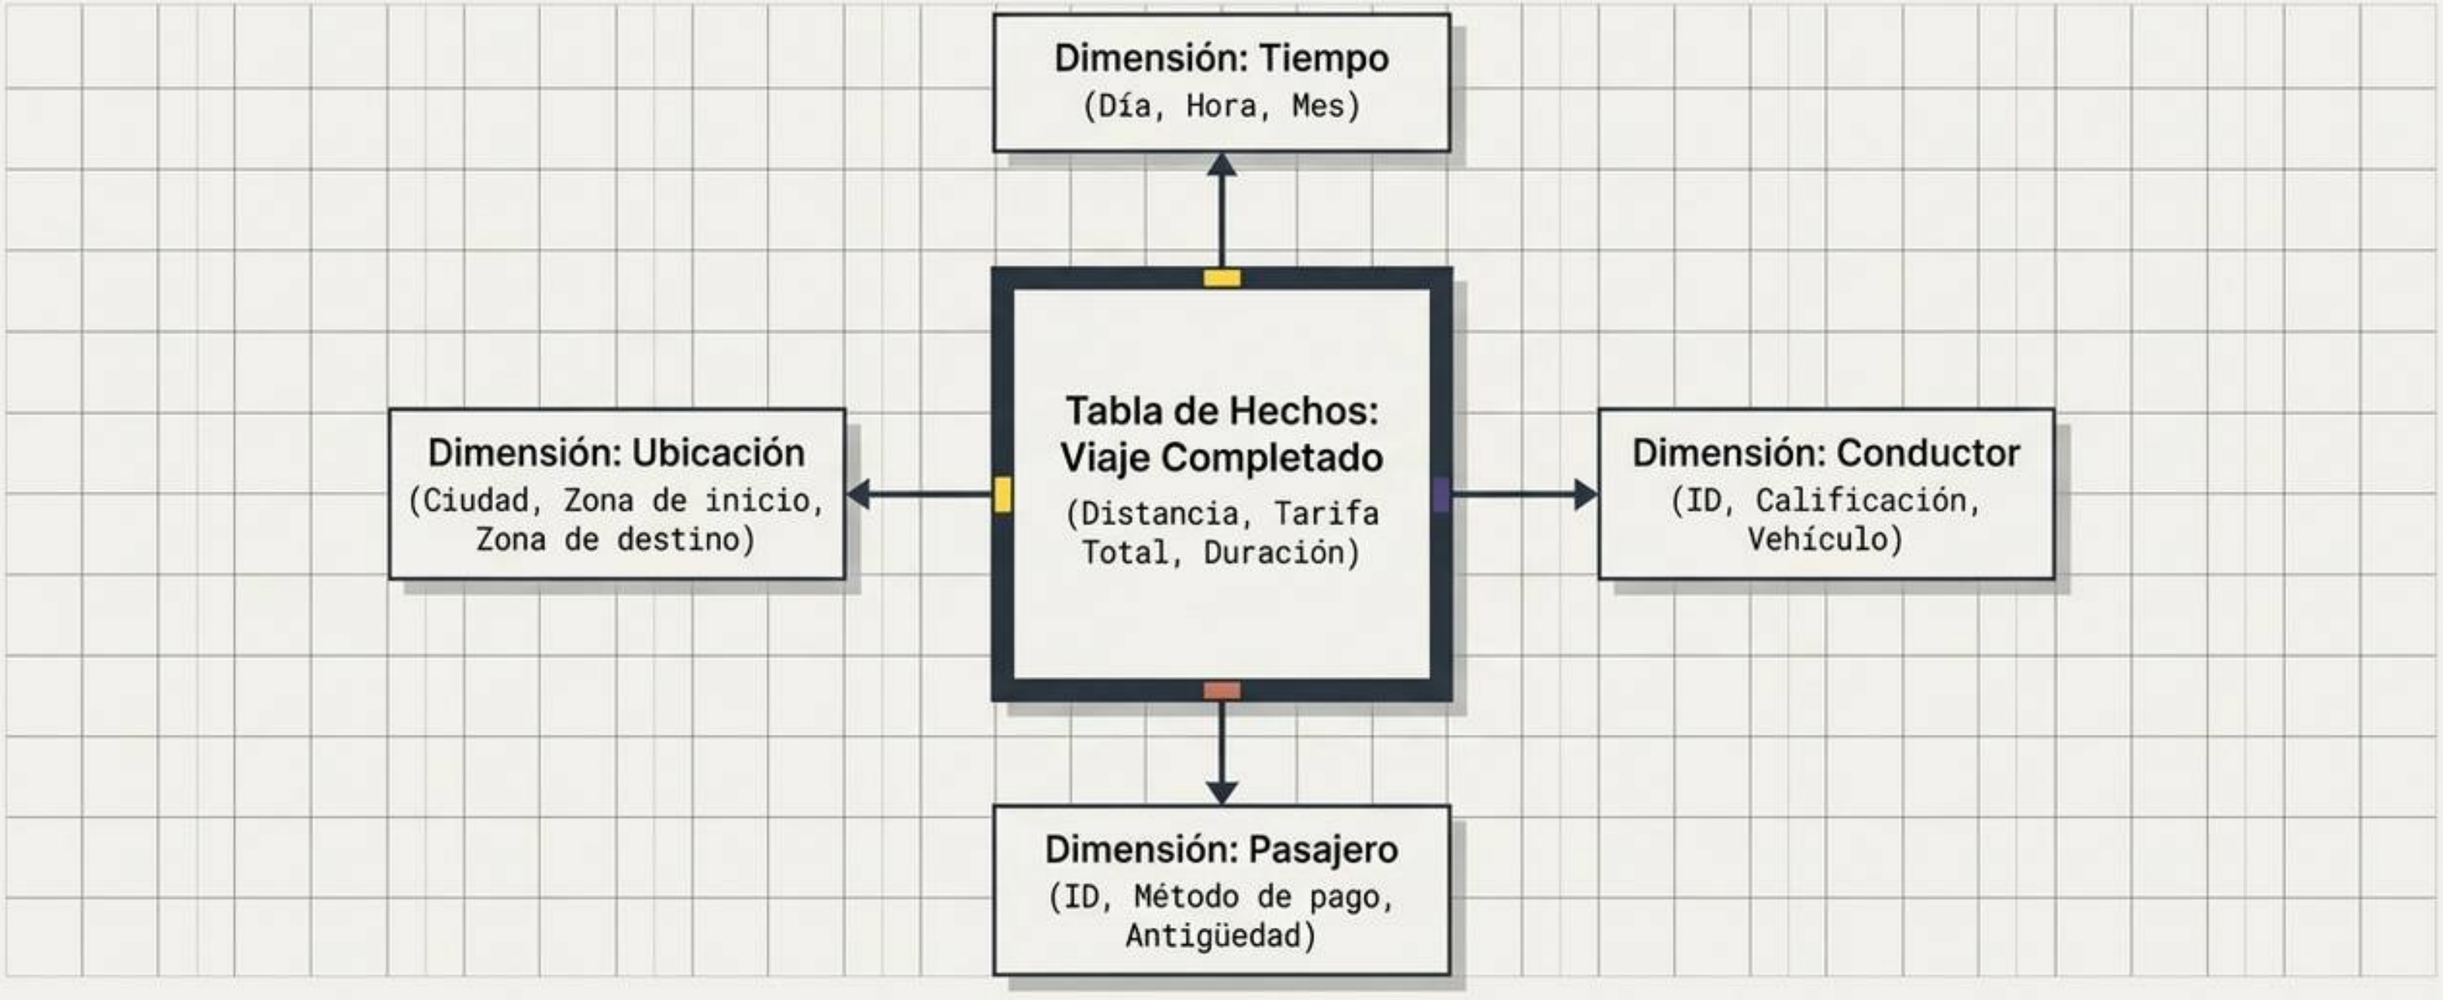

NotebookLM

Explotación: De la infraestructura a la inteligencia de negocio

En la capa final, el esfuerzo de ingeniería se traduce en interfaces visuales y motores predictivos que dictan la estrategia operativa de la empresa basándose en evidencia.

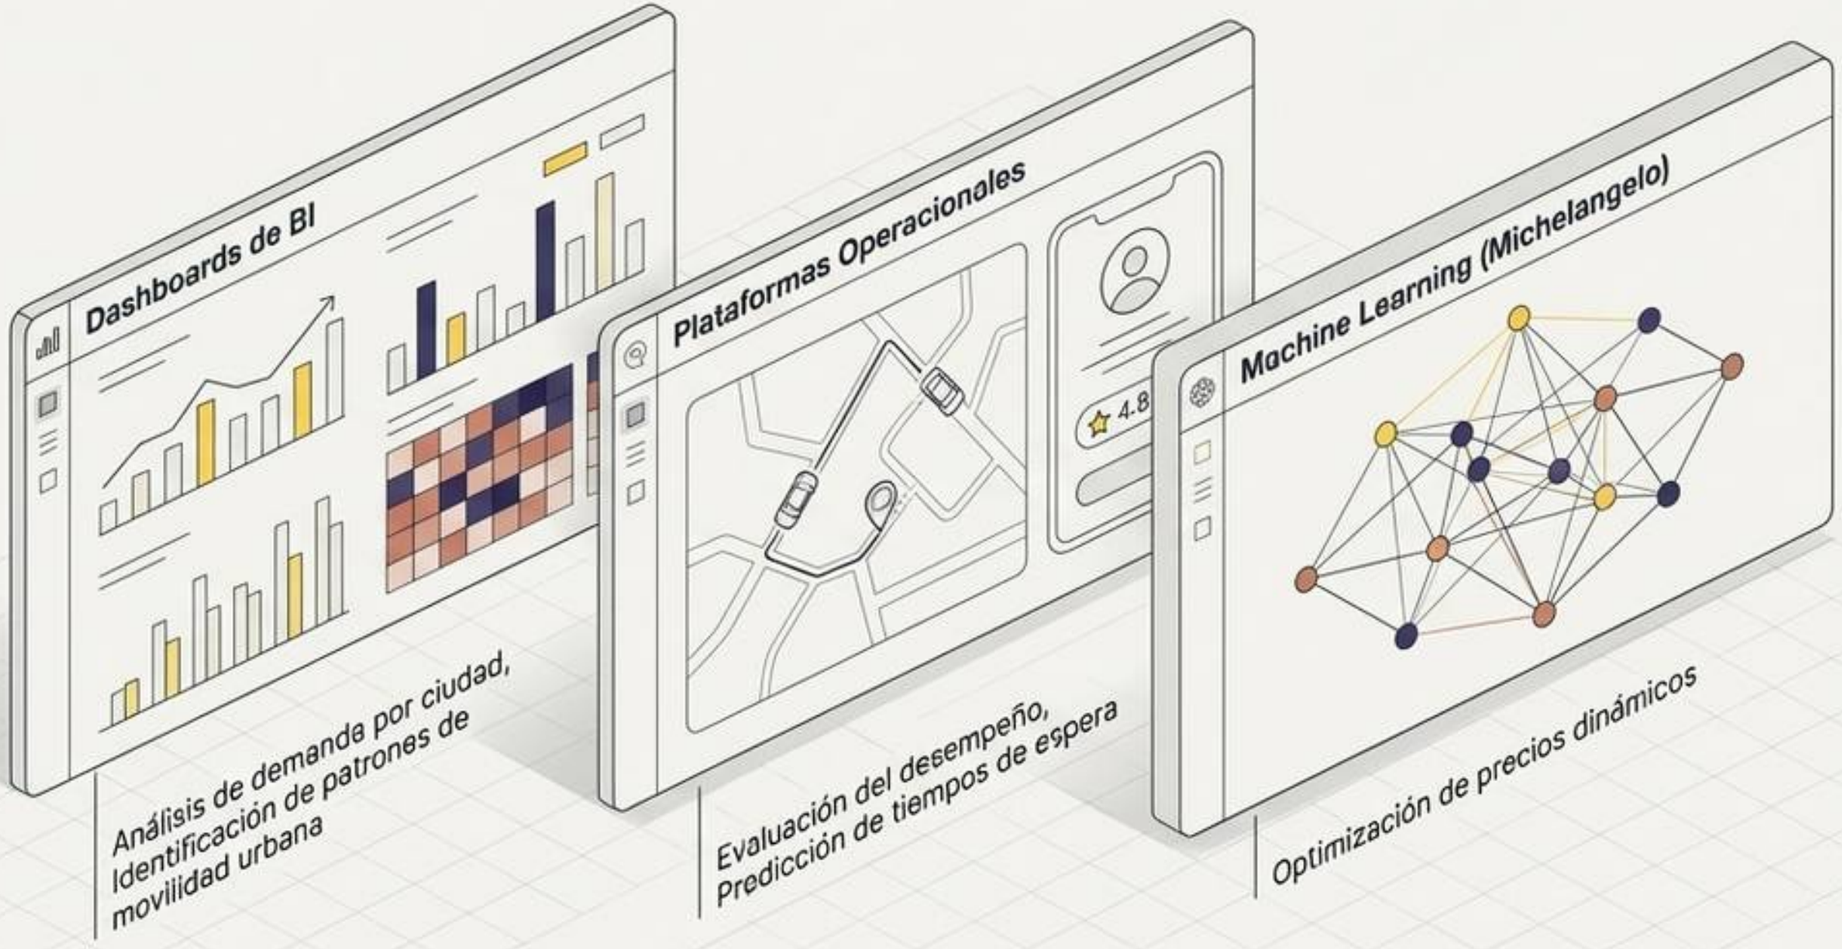

NotebookLM

Síntesis: De la señal bruta a la tarifa dinámica

La 'Tarifa Dinámica' no es magia; es la ejecución matemática de un pipeline perfecto en menos de 60 segundos.

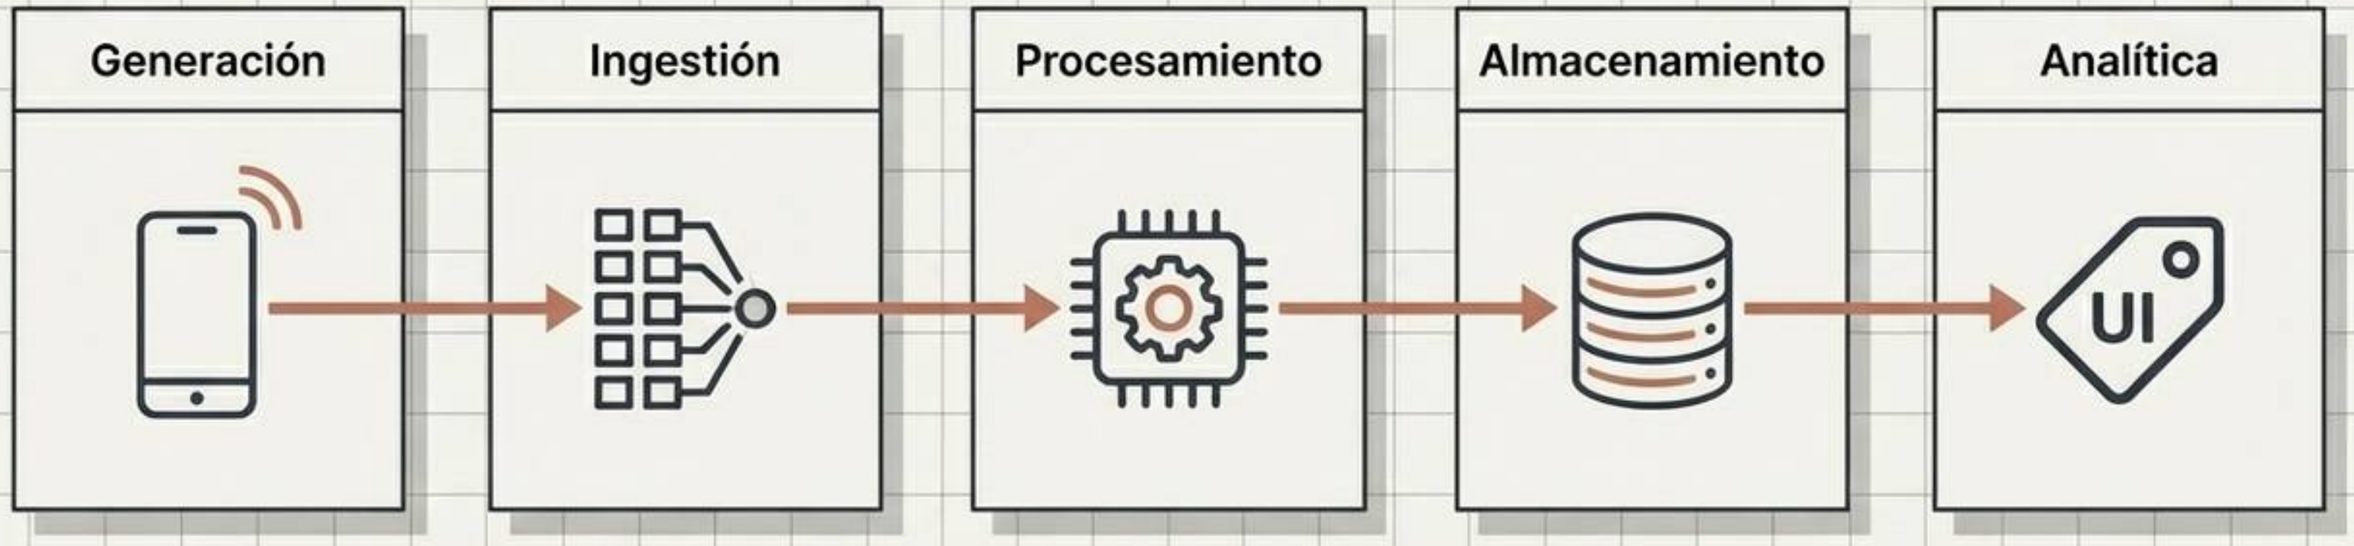

Generación: Señal GPS enviada desde la app.

Ingestión: Kafka captura el evento entre miles de otros.

Procesamiento: Spark calcula en tiempo real: baja oferta de conductores, alta demanda.

Almacenamiento: Registro escrito simultáneamente en el Data Warehouse.

Analítica: Algoritmo actualiza la app: Tarifa Dinámica 1.5x.

NotebookLM

El costo de la complejidad técnica frente al valor estratégico

Diseñar, mantener y escalar este sistema requiere equipos especializados en ingeniería de datos. Sin embargo, carecer de esta arquitectura garantiza ceguera operativa y estancamiento competitivo.

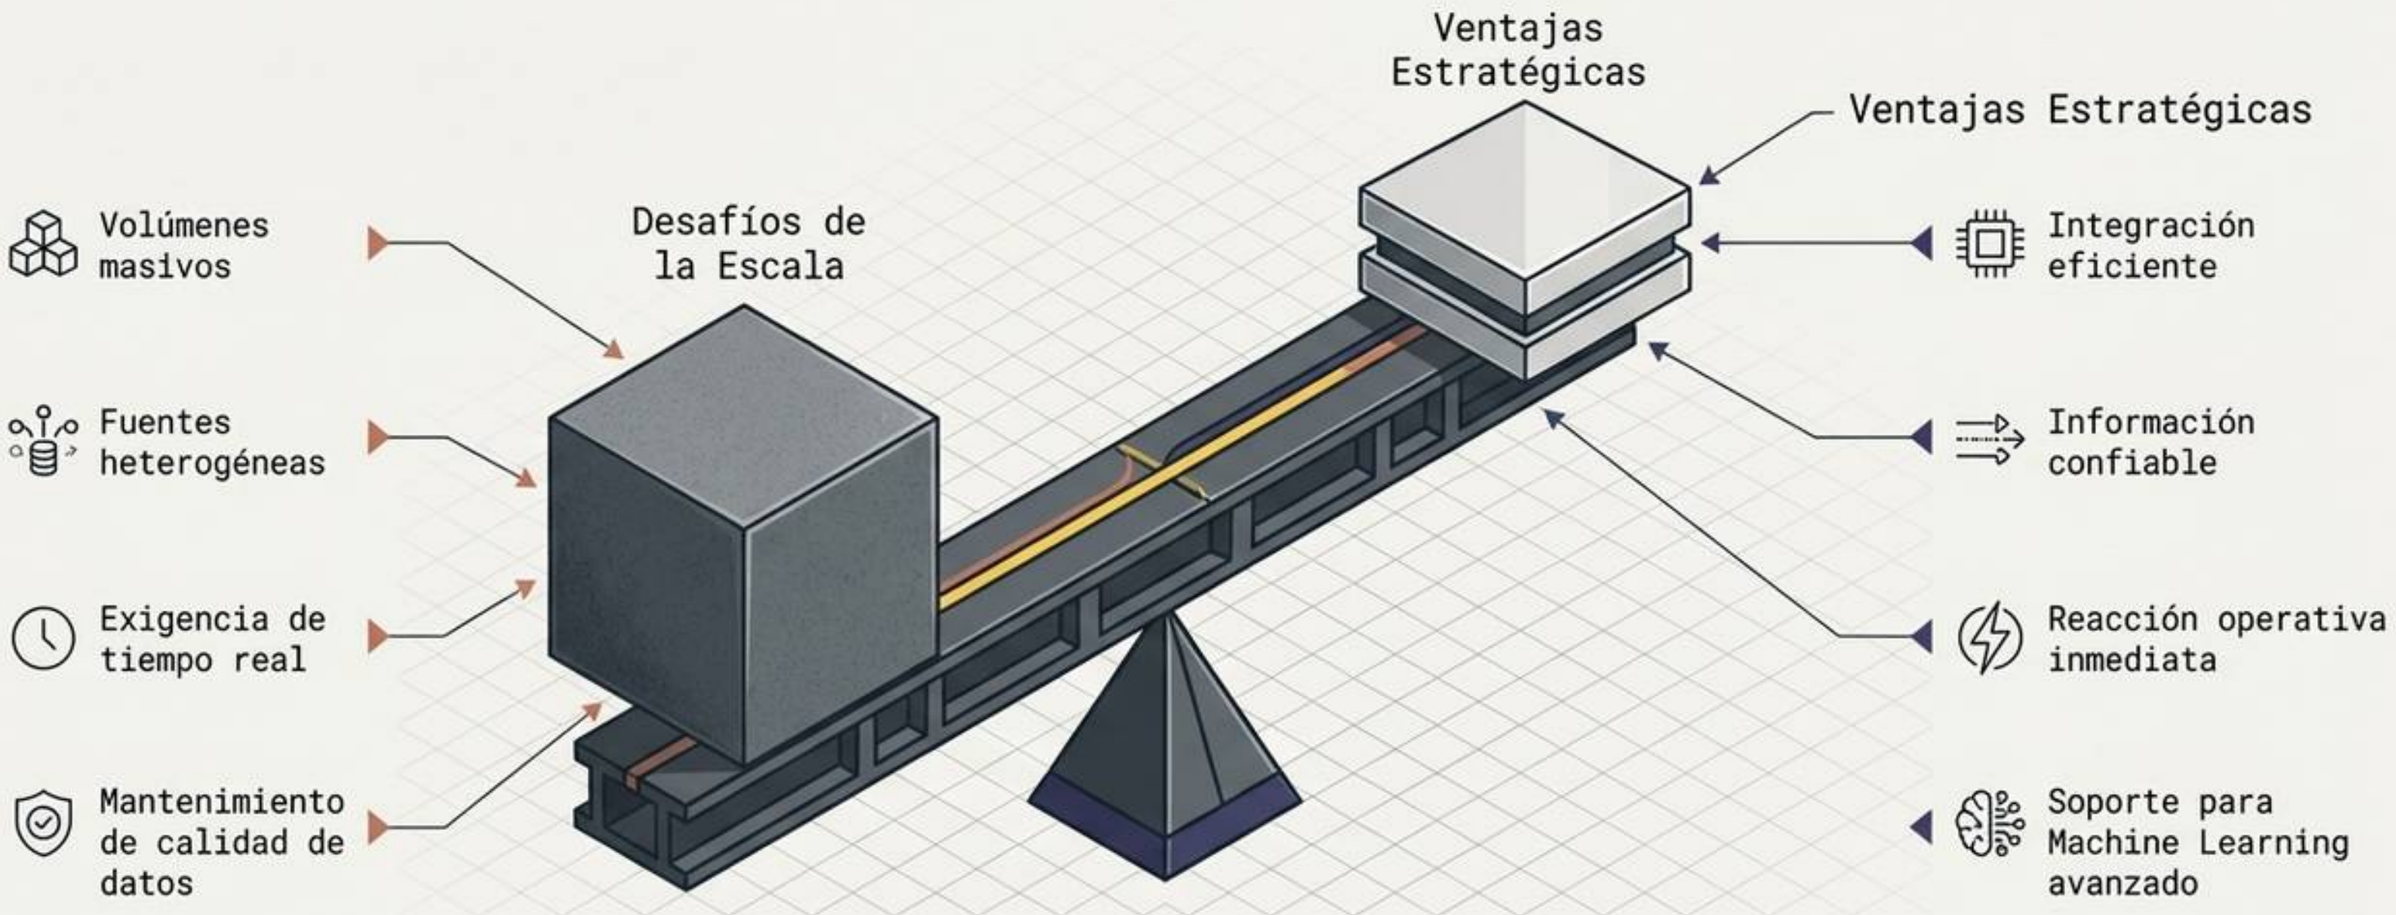

NotebookLM

Vectores de análisis continuo

Comprender esta arquitectura es el primer paso para diseñar soluciones equivalentes en cualquier industria moderna.

1. ¿Por qué el fracaso en estructurar un pipeline invalida cualquier proyecto de BI?
2. ¿Cómo impacta la variedad de fuentes (apps, GPS, pagos) en el diseño de la ingestión?
3. ¿En qué escenarios de su propia industria justificaría el costo del procesamiento en tiempo real?
3. ¿En qué escenarios de su propia industria justificaría el costo del procesamiento en tiempo real?
4. ¿Por qué la convivencia de Data Lakes y Data Warehouses es complementaria en lugar de redundante?
5. ¿Cuál es el riesgo operativo de depender de bases de datos tradicionales para analítica moderna?

Basado en el análisis de arquitecturas de Big Data de Uber Platforms (e.g., 100+ petabytes con latencia de minutos) y la plataforma de ML Michelang

NotebookLM