El Plano de Datos: Extracción ETL con Pentaho

Arquitectura visual para la captura y transformación de Web Services.

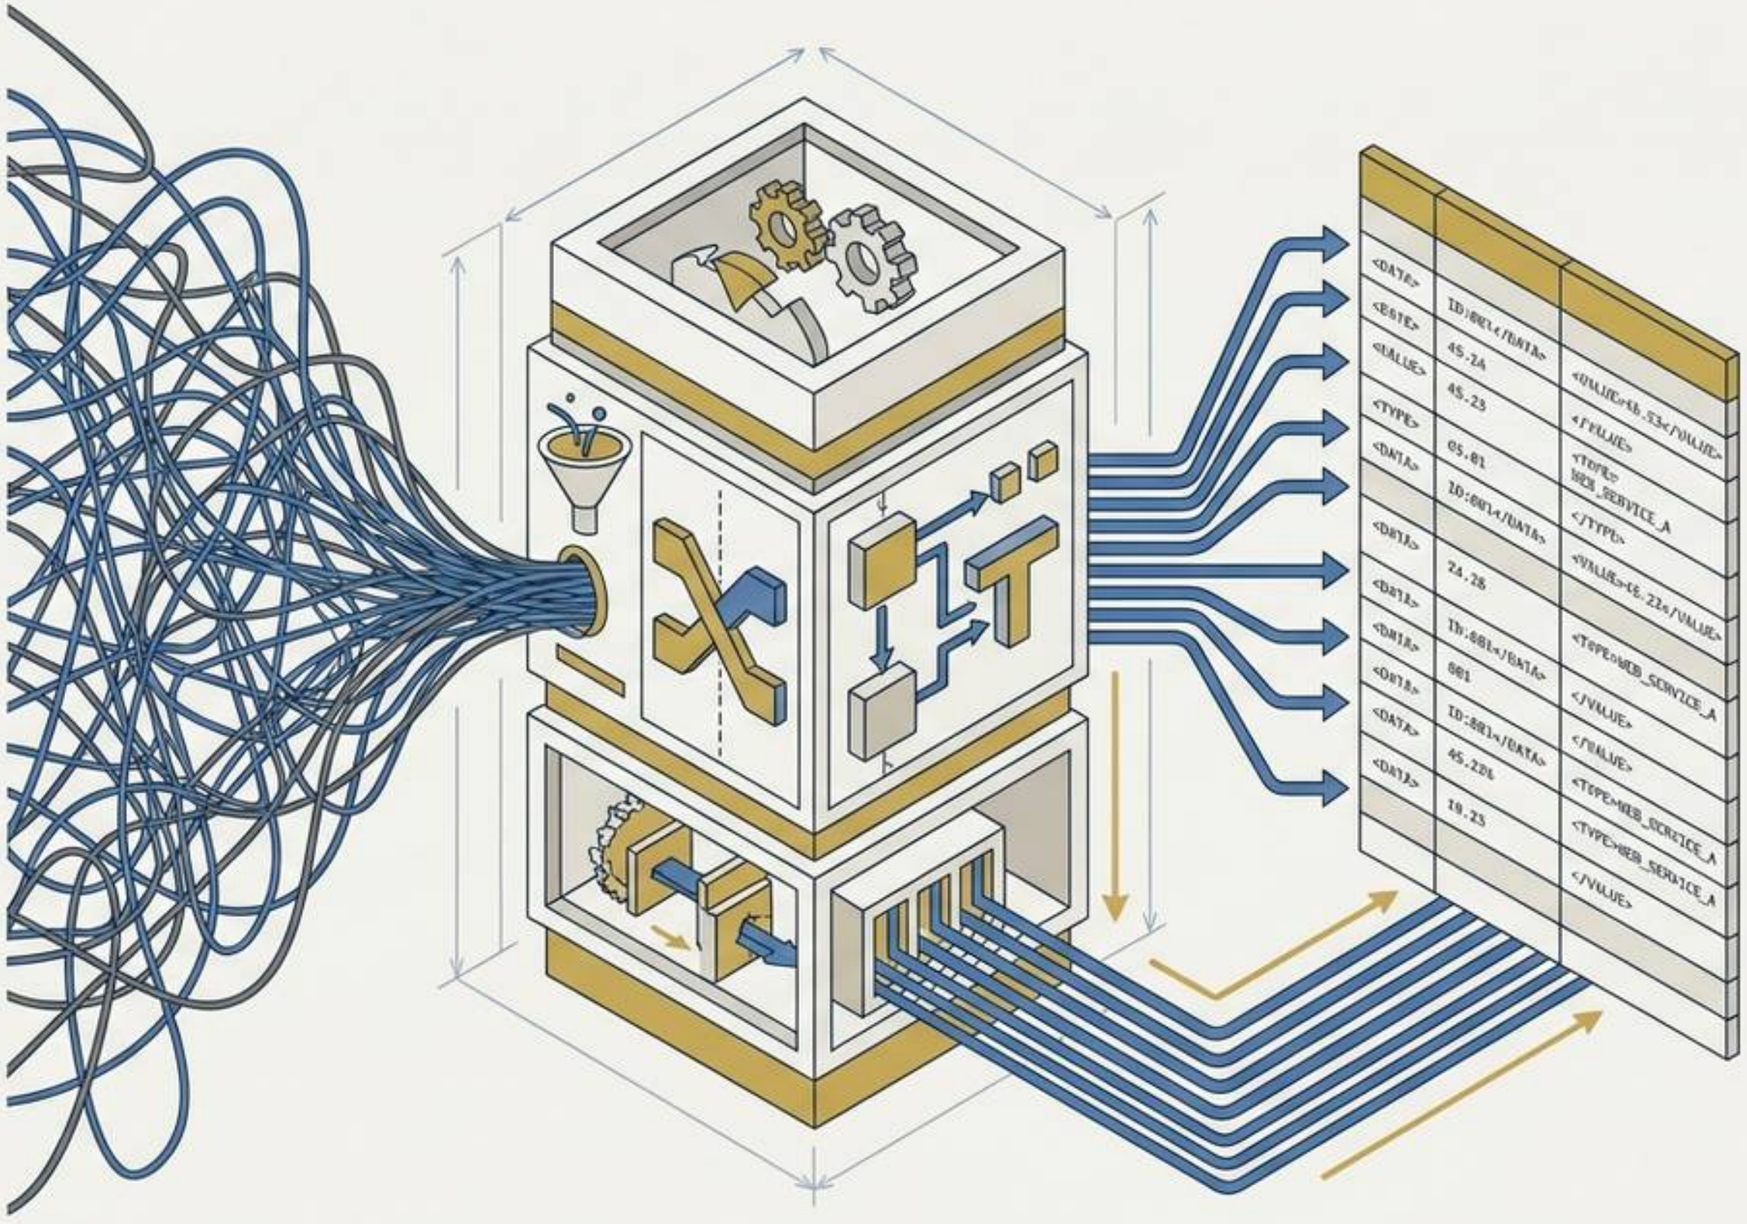

Dr. Julio Lopez-Nunez
2026

NotebookLM

El Objetivo: Desbloqueando Datos Públicos

La Fuente

Un Web Service público que expone datos parlamentarios.

El Protocolo

WSDL (Web Services Description Language), estructurado en formato **XML**.

El Objetivo

Extraer específicamente el celular y el email de cada diputado sin programar scripts complejos.

NotebookLM

La Anatomía de una Tubería ETL

En Pentaho Data Integration (PDI), no escribimos código secuencial; construimos una línea de ensamblaje de datos conectando nodos especializados.

NotebookLM

Conectando a la Fuente: El Menú WSDL

Web Services Lookup

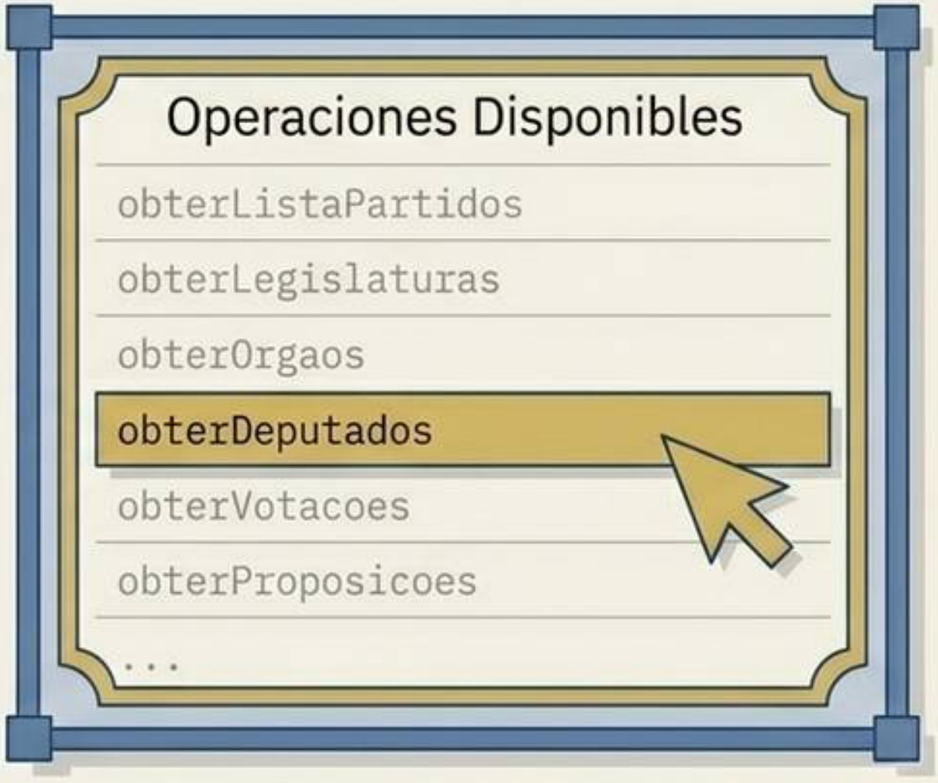

Paso 1: Ingresar la URL del WSDL y ejecutar Load. → Paso 2: El sistema expone todas las operaciones. → Paso 3: Seleccionar la operación deseada (obterDeputados). PDI autoconfigura la recepción.

NotebookLM

La Carga Bruta: Un Solo Registro XML

El Resultado Inicial

El componente Web Services Lookup captura toda la información del sitio web en una sola transacción.

Al hacer `Preview`, no vemos una tabla estructurada, sino un bloque denso de código XML comprimido en una única fila.

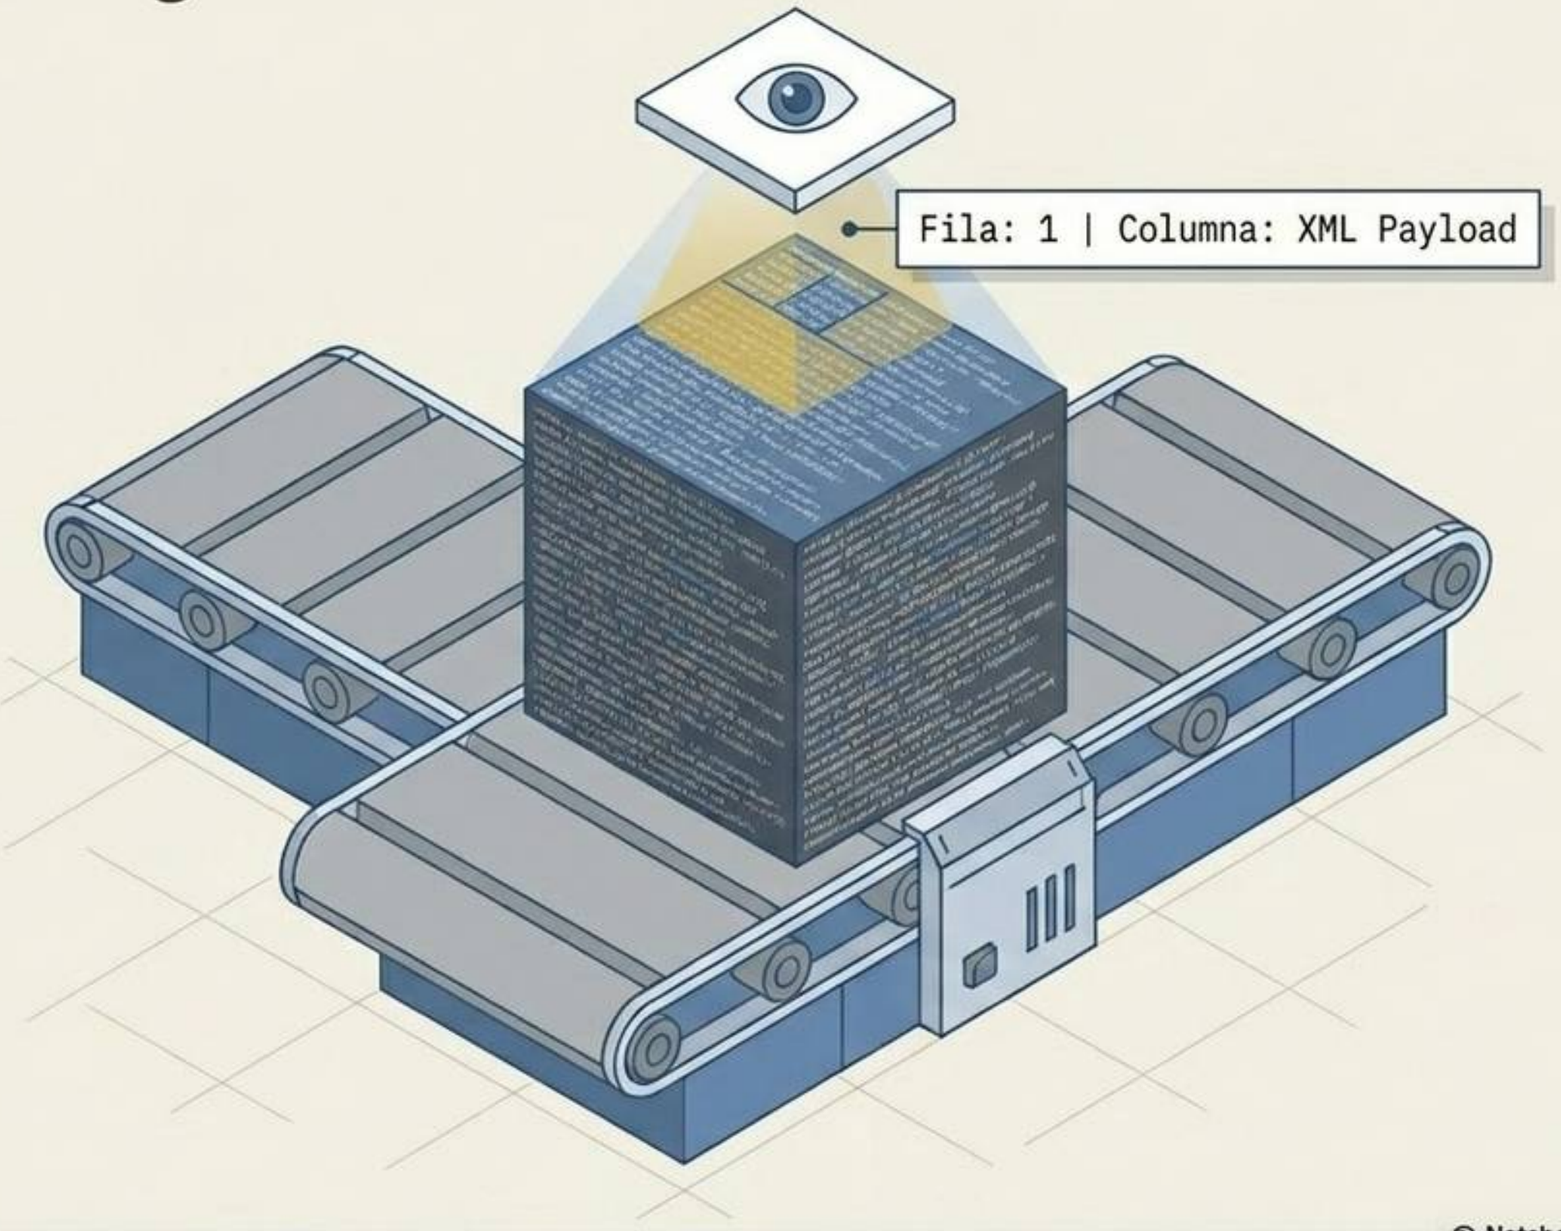

NotebookLM

Desglosando el XML: La Ruta de Extracción

Para aislar la información, debemos trazar la ruta exacta a través de la jerarquía XML hasta la etiqueta en singular.

Es allí donde residen los datos valiosos a extraer.

NotebookLM

Disección de DDI Datos: Nodos vs. Atributos

Nodo (Nuestro Objetivo)	Atributo (No Utilizado Aquí)
`<email>dato@gob.br</email>`	`<deputado email="dato@gob.br">`
El dato es el contenido encerrado entre las etiquetas de apertura y cierre. PDI extraerá el valor interno del nodo.	El dato es una propiedad alojada directamente dentro de la propia etiqueta de apertura. Requiere una configuración distinta en PDI.

NotebookLM

Estandarización: Todo Nace como Texto

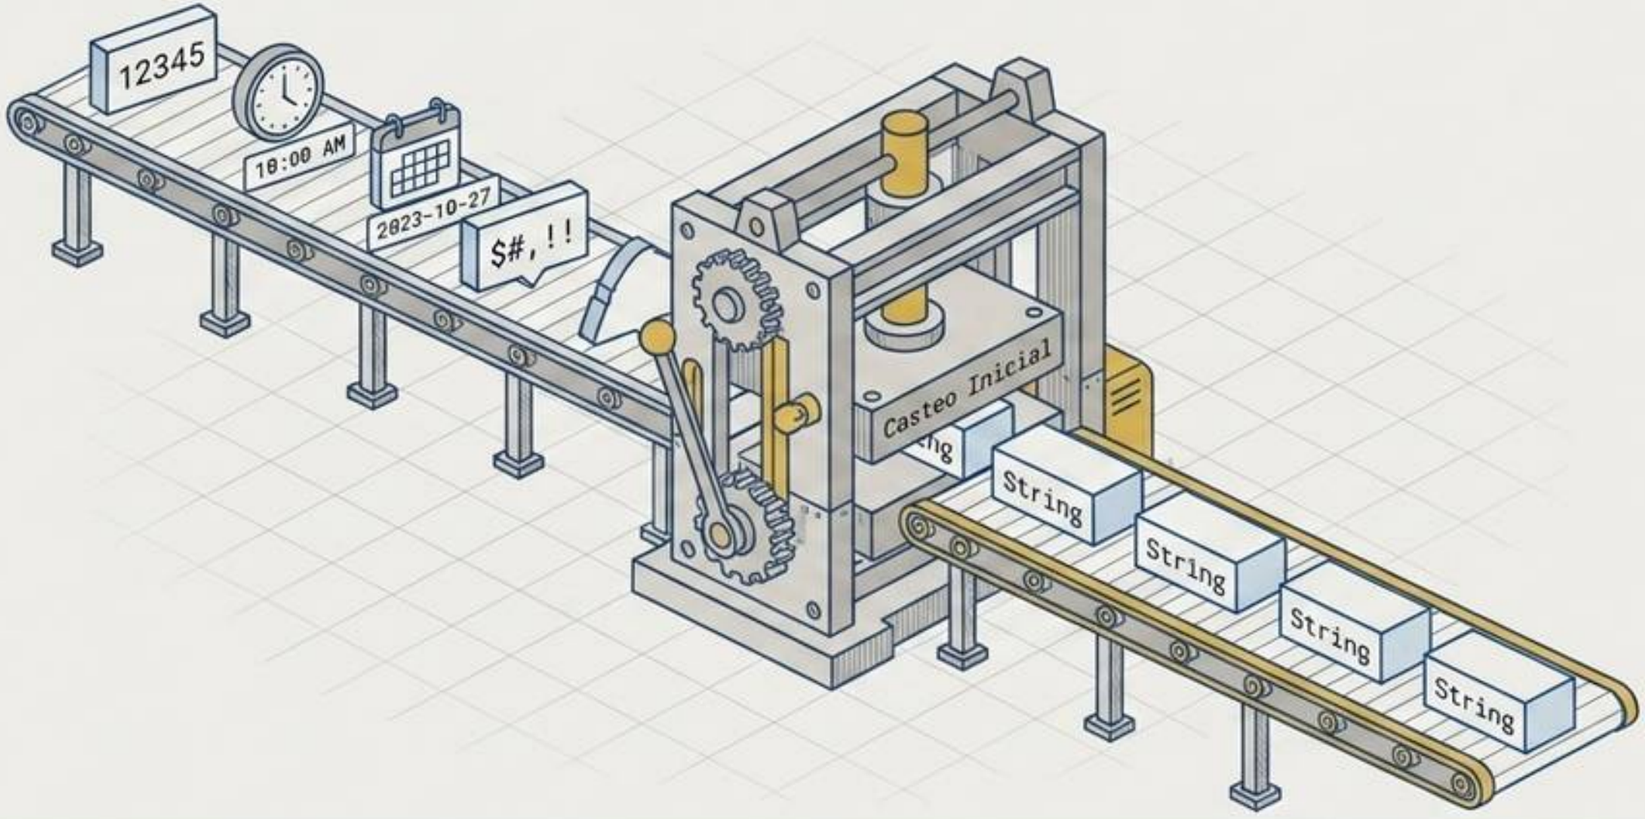

Formato Recomendado	¿Por qué?
Configurar todos los campos capturados como String (Texto).	Extraer números telefónicos o IDs como texto inicialmente evita errores de formato, truncamientos por ceros a la izquierda o conflictos de metadatos. La conversión a formato numérico (Integer) o fecha (Date) debe ocurrir en etapas posteriores.

NotebookLM

Limpieza y Salida: Descartando el Molde

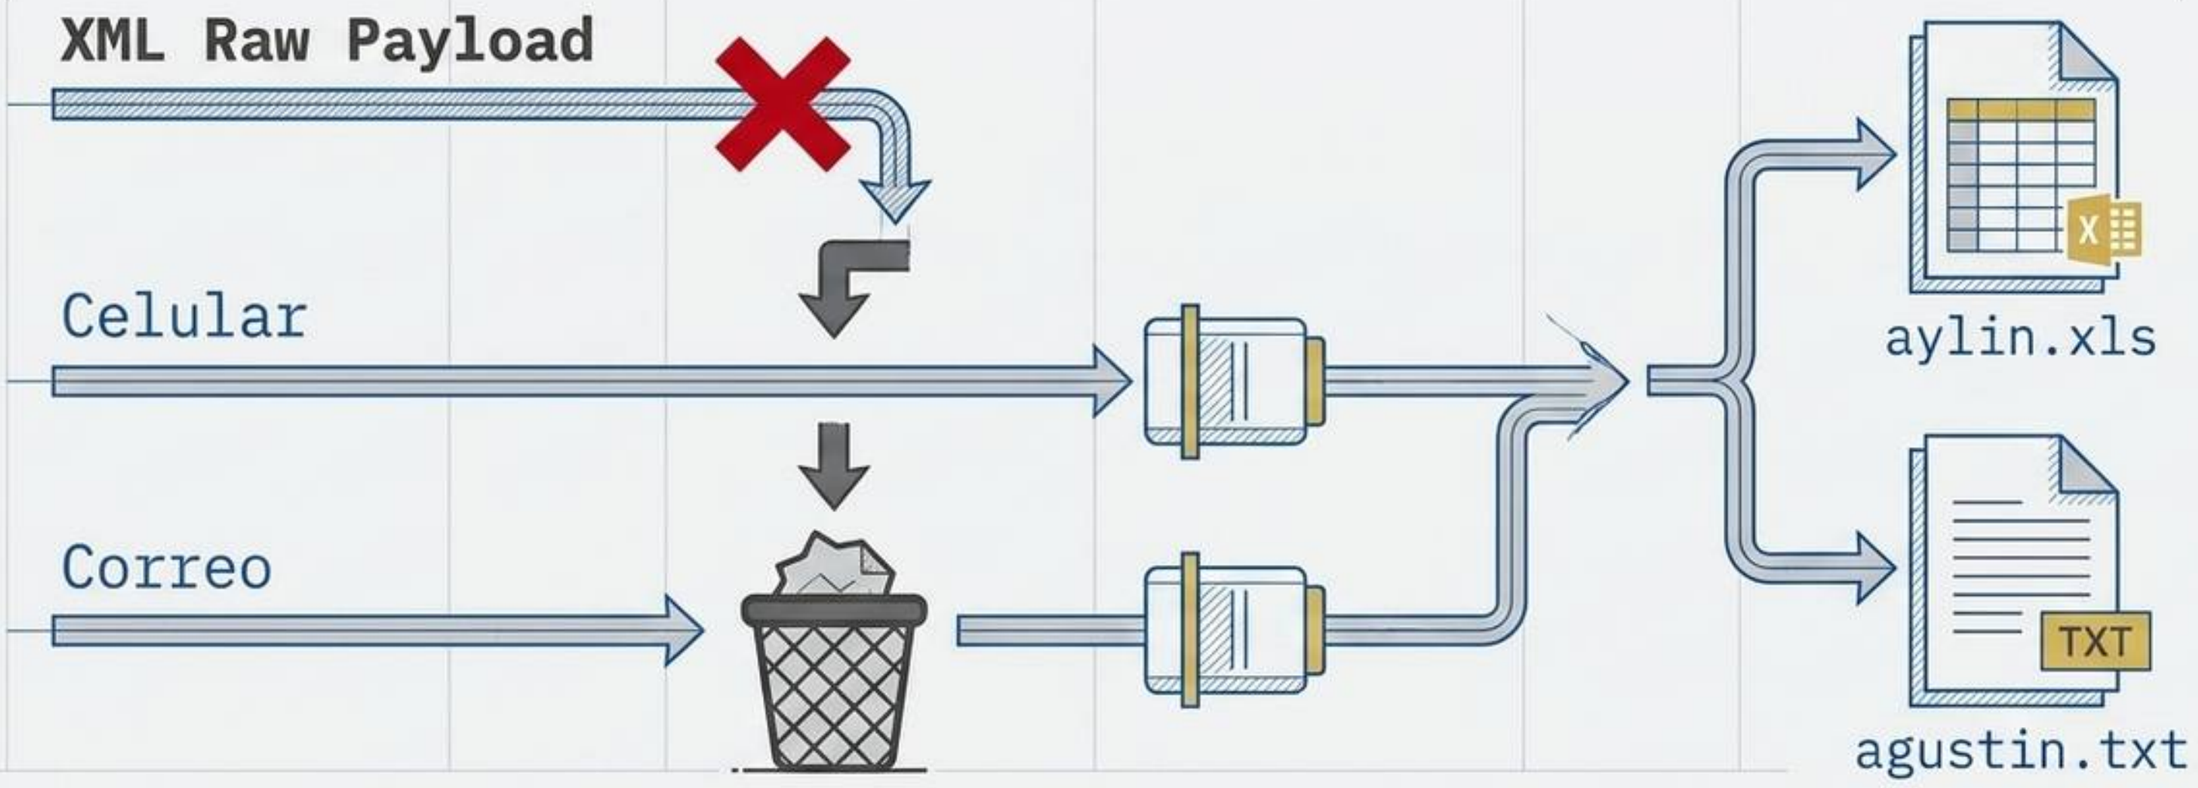

En la configuración final de salida, es indispensable eliminar el campo original que contiene el masivo bloque XML. Solo los campos parseados (celular, correo) deben llegar al archivo físico final.

NotebookLM

Lógica de Distribución en PDI

Comportamiento por defecto: Distribución, no duplicación.

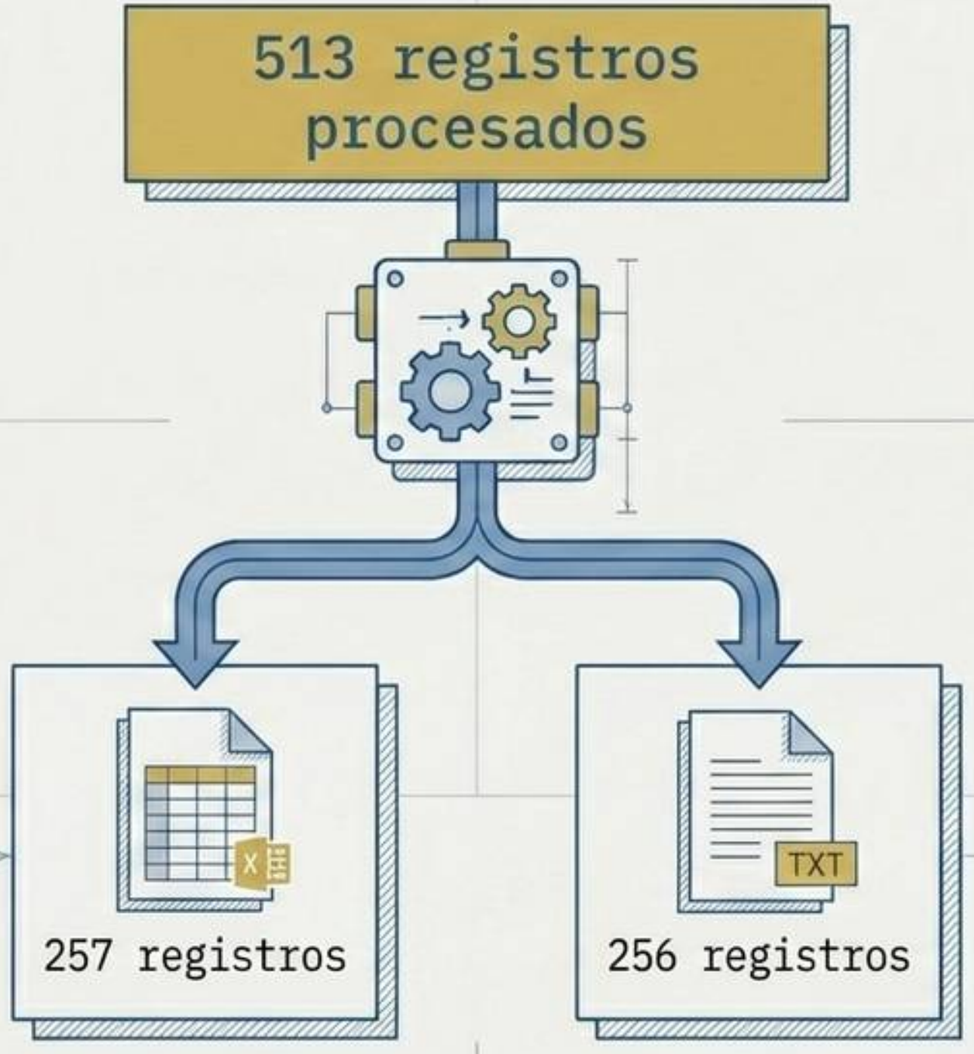

Si se conectan múltiples salidas a un solo nodo, PDI divide equitativamente la carga de datos entre los destinos (257 + 256 = 513). No envía la totalidad de los registros a cada uno.

NotebookLM

Prevención de Fallos: El Flujo de Errores

PDI no tiene por qué detenerse ante un fallo. Utilizando la flecha roja de salida, los registros corruptos o errores de conexión se desvían a una bitácora aislada. Esto permite documentar el fallo mientras el flujo principal de datos exitosos continúa ininterrumpido.

NotebookLM

El Panel de Telemetría

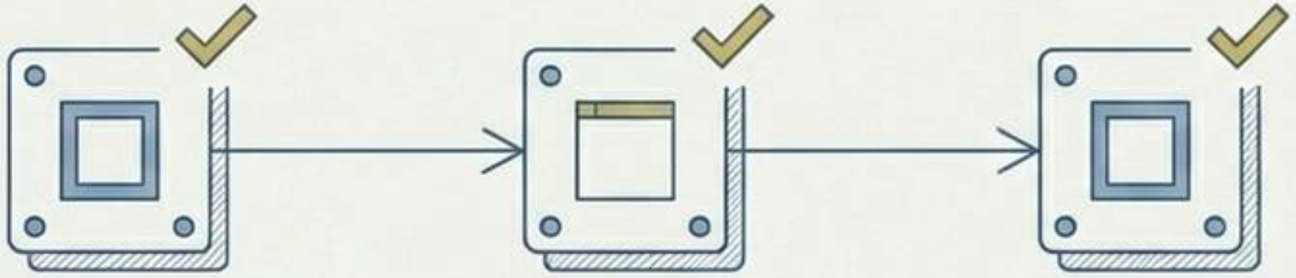

Step Name	Read	Written	Time
Web Services Lookup	0	1	0.5s
Get Data from XML	1	513	1.2s
Text file output	256	256	0.1s

La ejecución exitosa transforma el lienzo. El panel inferior expone métricas exactas, confirmando el volumen de procesamiento de lectura/escritura y los tiempos de latencia por cada etapa.

NotebookLM

El Ecosistema Completo

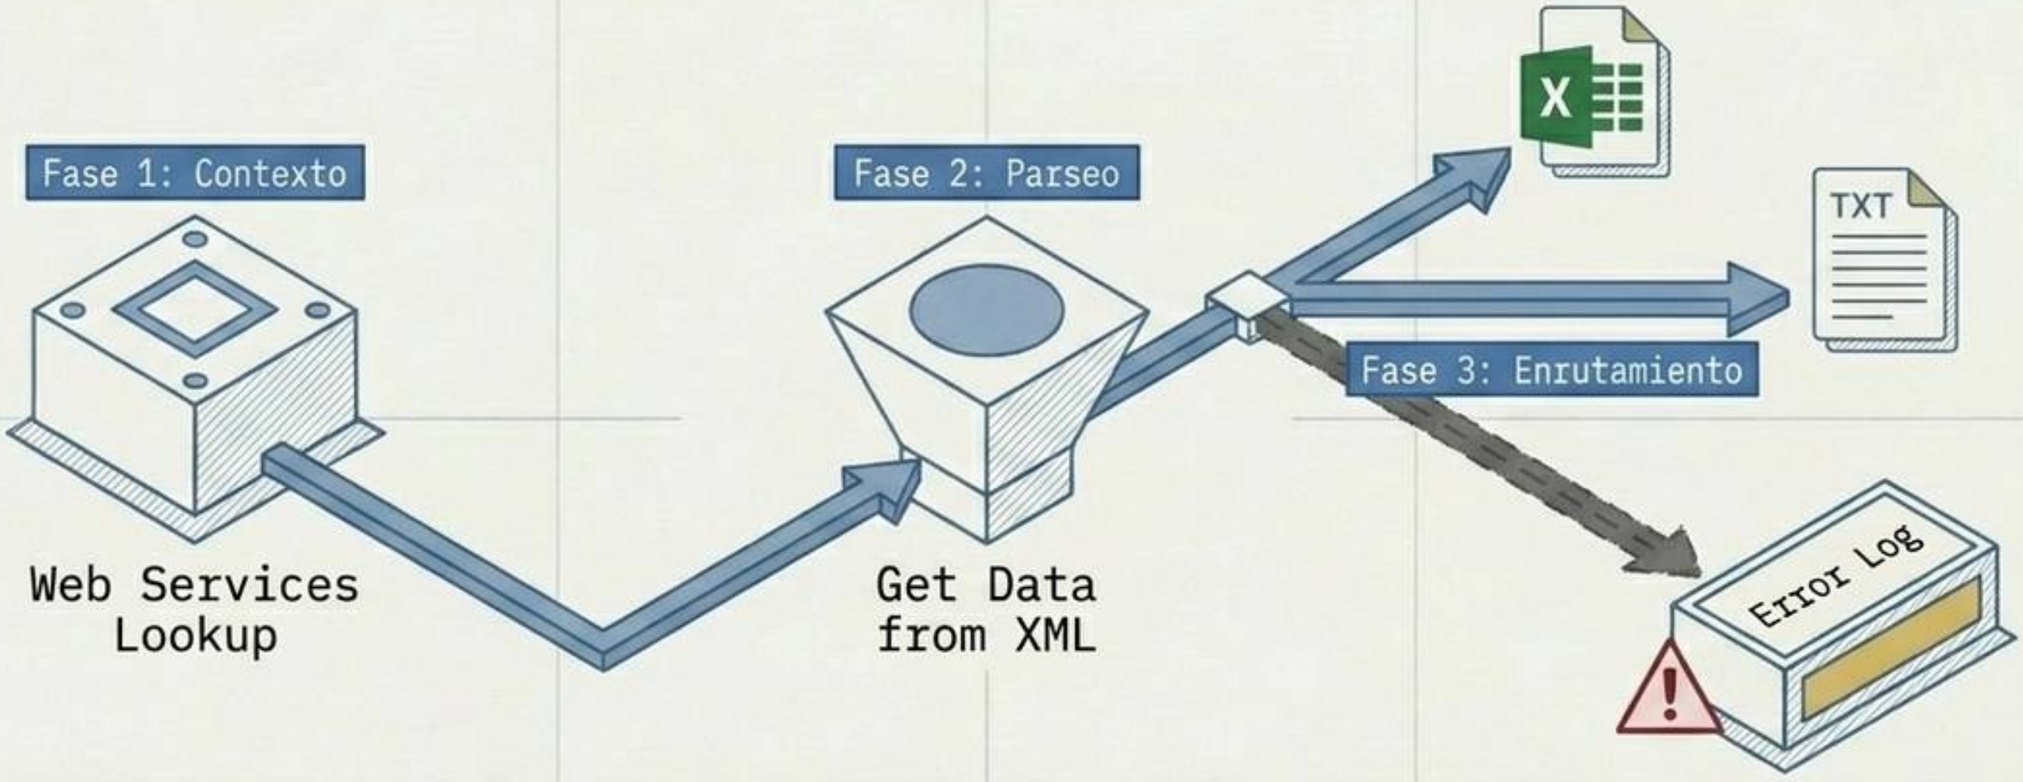

De un concepto abstracto a una arquitectura física. Hemos traducido un servicio web complejo en un flujo de datos autónomo, filtrado y balanceado, listo para integrarse en cualquier entorno analítico.

NotebookLM